Zoom in论文调研

Zoom-In思考

表面理解：放大图像区域，"把图像的某个区域裁剪出来、放大、重新看"

深层本质：视觉带宽的动态重分配

VLM有一个固定的"视觉带宽"——它能处理的视觉token总数是有上限的（context length约束）问题是：

一张4K图像 (3840×2160)—— ViT编码 (patch_size=14)——理论上需要: (3840/14) × (2160/14) ≈ 42,000 个token

实际能处理: ~1,000 个token (context length约束)——实际降采样输入: 约 384×384 → ~750个token

1、Open-o3-Video: Grounded Video Reasoning with Explicit Spatio-Temporal Evidence

开源：https://marinero4972.github.io/projects/Open-o3-Video/

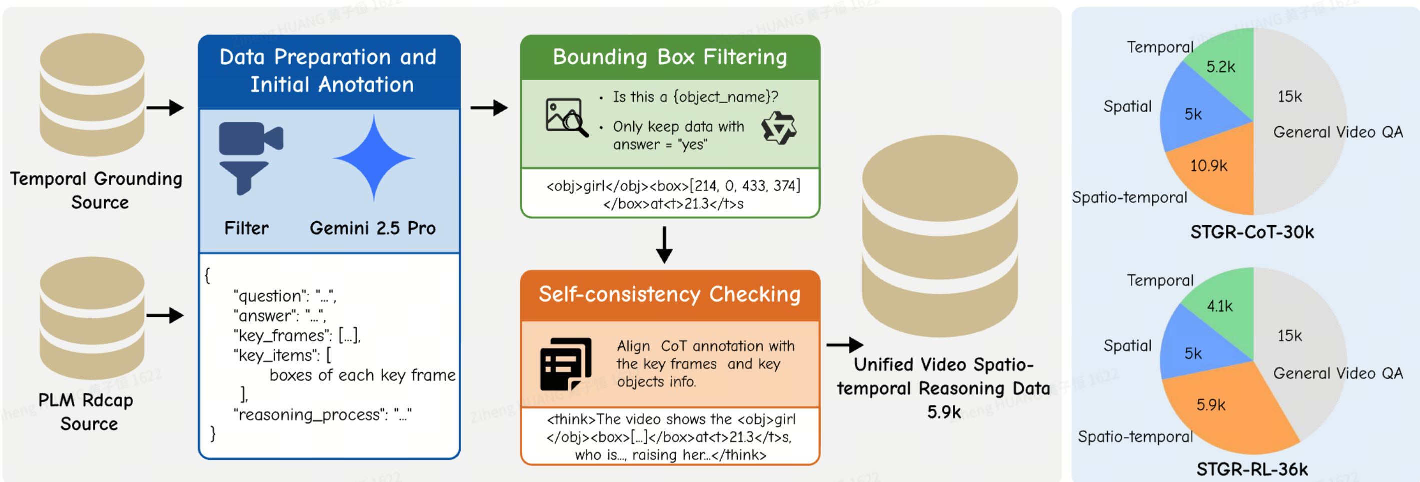

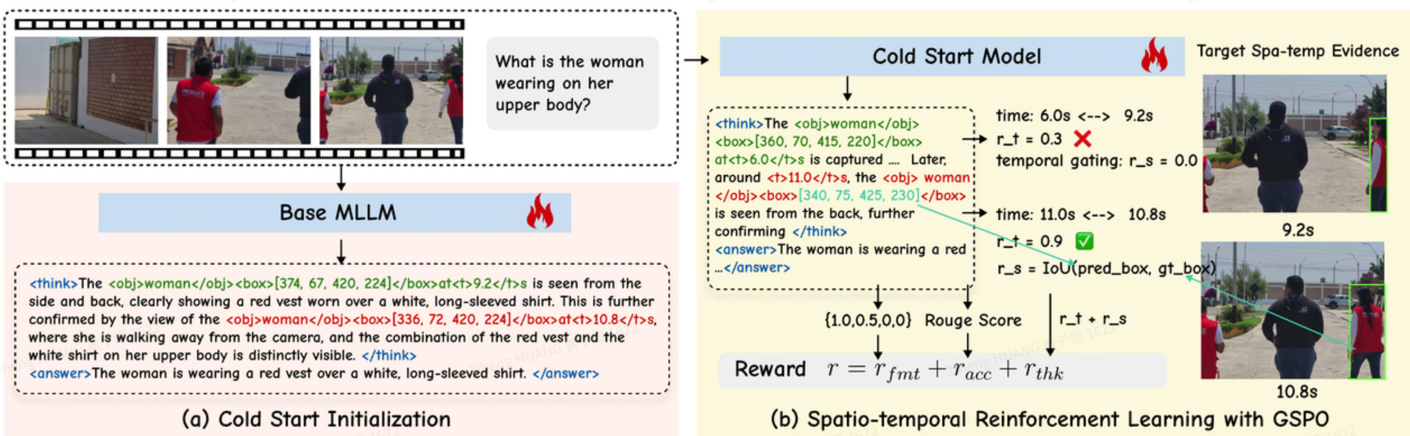

$$
r_t(x,y)=\begin{cases}\dfrac{1}{M}\displaystyle\sum_{m=1}^{M}\mathbf{1}\left[s^{\mathrm{gt}}\le t_m\le e^{\mathrm{gt}}\right], & \tau_t=\mathrm{Int},\\ \dfrac{1}{M}\displaystyle\sum_{m=1}^{M}\exp\left(-\dfrac{\Delta t_m^2}{2\sigma^2}\right), & \tau_t=\mathrm{Pt},\\ 0, & \tau_t=\varnothing.\end{cases}
$$

adaptive temporal proximity：一开始就把时间门槛设得很严，早期训练几乎拿不到奖励；但如果一直设得很松，时间奖励又会很快饱和，模型不会继续把时间戳往真值逼近。所以他们让时间容忍度**前期大、后期逐步收紧**，先学粗定位，再学精定位

temporal gating：空间奖励只有在“预测时间已经足够接近真值”时才计算，避免模型在错误时间点上框出某个“看起来显眼但其实不相关”的东西，却仍然拿到空间奖励。

2、Grounded Reinforcement Learning for Visual Reasoning

开源：https://visually-grounded-rl.github.io/

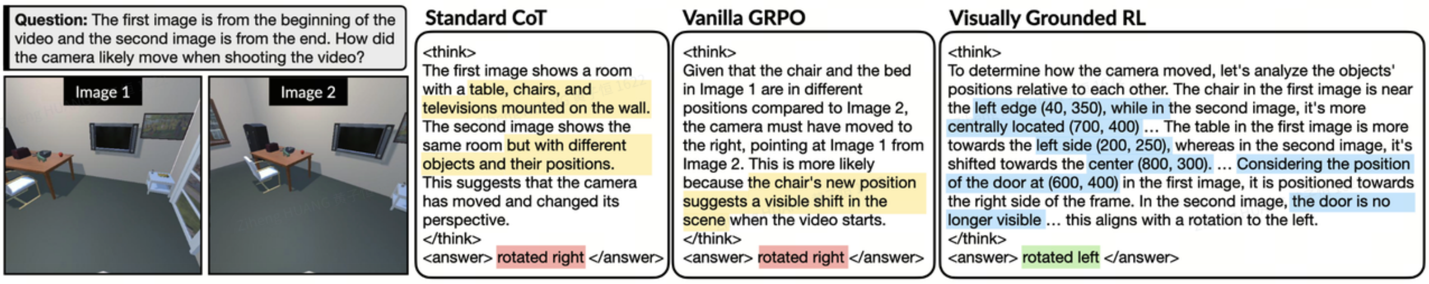

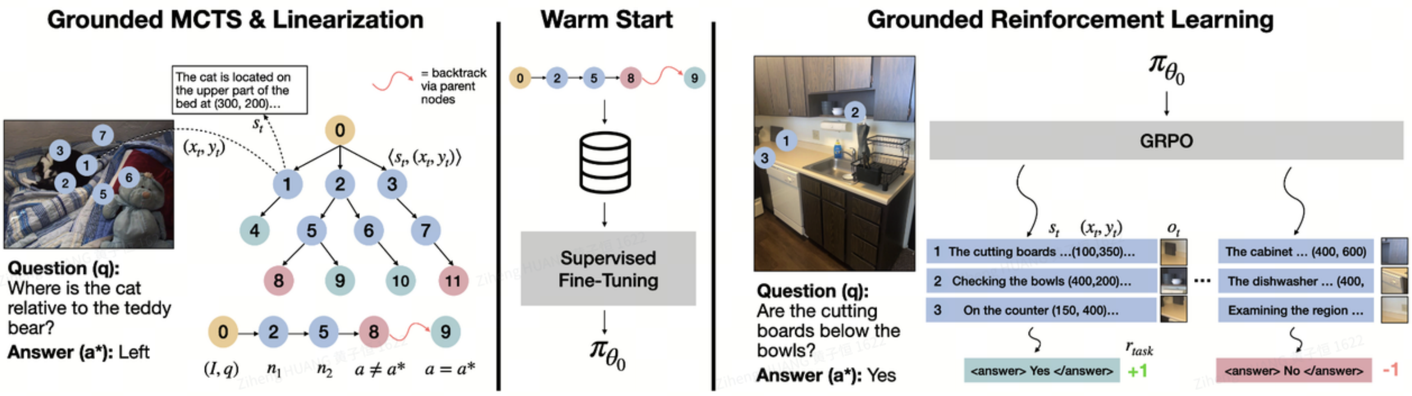

树里的每个节点对应一个 reasoning step（`<think>` 或 `<answer>`），根节点是原始问题；节点会维护当前文本、已经访问过的坐标、价值估计和访问次数。搜索过程还是标准四步：Selection、Expansion、Rollout、Backpropagation。Expansion 时每个节点最多生成 3 个子节点；Rollout 用 VLM 自己继续推理到终局，再由 judge 按最终答案给 0/1 奖励；最后把这个奖励往树上回传

Table 1: Performance (mean ± 95% CI) on ScreenSpot and VisualWebArena. Multi-t = multi-turn RL with visual feedback.

Model	ScreenSpot -V2	ScreenSpot -Pro	VWA (Vision Only)
Proprietary Models			
GPT-4o	18.1	0.8	19.8 (w/ text)
Claude Comp. Use	-	17.1	–
Open-source Models			
Qwen2-VL-7B	-	1.6	2.9 (w/ text)
Kimi-VL-16B-MoE	92.8	34.5	–
Web Grounding Models			
SeeClick	55.1	1.1	–
CogAgent-18B	-	7.7	–
OS-Atlas-4B	71.9	3.7	–
OS-Atlas-7B	84.1	18.9	–
ShowUI-2B	-	7.7	–
UGround-7B	-	16.5	–
UGround-V1-7B	–	31.1	–
UI-TARS-2B	84.7	27.7	–
UI-R1-3B	–	17.8	–
ICAL-7B	–	-	8.2 (w/ text)
Method Comparison			
Qwen2.5-VL-3B	68.4 (±2.6)	23.9	4.2 (±1.3)
+ SFT direct	80.6 (±2.2)	25.0 (±2.1)	4.5 (±1.4)
+ Vanilla GRPO	84.4 (±2.0)	29.0 (±2.2)	4.8 (±1.4)
ViGoRL-3b (Ours)	**86.5** (±1.9)	**31.1** (±2.3)	**6.4** (±1.5)
Multi-t ViGoRL-3b (Ours)	**86.1** (±1.9)	**32.3** (±2.4)	-
Qwen2.5-VL-7B	73.6 (±2.4)	29.0	5.5 (±1.5)
ViGoRL-7b (Ours)	**91.0** (±1.6)	**33.1** (±2.3)	**11.2** (±2.1)

Table 2: Accuracy (mean ± 95% CI) for spatial reasoning.

Model	SAT-2 Val	BLINK	RoboSpatial
Proprietary Models			
GPT-4o	–	60.0	76.2
GPT-4 Turbo	–	54.6	–
Claude 3 Opus	–	44.1	–
Gemini Pro 1.0	–	45.2	–
General Open-source Models			
LLaVA v1.6 34B	–	46.8	–
instructBLIP 13B	–	42.2	–
Molmo	–	-	67.1
Method Comparison			
Qwen2.5VL-3B	46.1 (±1.5)	44.4 (±2.3)	54.4 (±6.5)
+ SFT direct	58.3 (±1.5)	46.4 (±2.3)	62.3 (±6.3)
+ Vanilla GRPO	50.0 (±1.6)	46.5 (±2.3)	**69.7** (±6.0)
ViGoRL-3b (Ours)	**62.9** (±1.5)	**48.5** (±2.3)	**67.1** (±6.1)
Qwen2.5-VL-7B	52.6 (±1.6)	52.9 (±2.3)	46.7 (±9.5)
ViGoRL-7b (Ours)	**67.5** (±1.5)	**54.1** (±2.3)	**76.4** (±7.5)

概述

一、图片 Zoom-In 方案

1.1 Training-Free（无需训练）

方法	时间	会议	核心思路	Zoom 实
V* (SEAL)	Dec 2023	CVPR 2024	LLM引导的视觉搜索	递归四分 优先级逐
ZoomEye	Nov 2024	EMNLP 2025 Oral	树搜索模拟人类zoom	图像建树 zoom子[illegible] GPT-4o
MLLMs Know Where to Look	Feb 2025	ICLR 2025	利用MLLM内部注意力定位	基于atte crop再输
DyFo	Apr 2025	CVPR 2025	MCTS动态聚焦	Monte Ca zoom/pa
Zoom-Refine	Jun 2025	—	MLLM自定位+自精炼	模型预测 推理，无
HiDe	Oct 2025	—	重新思考zoom-in（背景干扰才是关键）	Token注 持解耦，
Q-Zoom	Apr 2026	—	查询感知自适应感知	动态门控 1024 tok

1.2 RL训练（强化学习）

方法	时间	核心思路	Zoom 实现
DeepEyes	May 2025	RL端到端学习interleaved多模态CoT	推理中调用zoo bbox→crop回[illegible]
Chain-of-Focus	May 2025	SFT+RL自适应zoom决策	多轮生成：输出 新回答
VLM-R3	May 2025	区域识别+推理+精炼	R-GRPO奖励选[illegible] zoom交织CoT
ViGoRL	May 2025	视觉锚定RL	每步发射坐标→
ACTIVE-O3	May 2025	纯RL主动感知	学习sensing策[illegible]
CropVLM	Nov 2025	轻量外接crop模块(256M)	RL训练，即插[illegible]
AdaptVision	Dec 2025	粗到精自适应	先1/4分辨率，[illegible] crop
TikArt	Feb 2026	Think-Aperture-Observe循环	Zoom(矩形crop Segment(SAM2

二、视频 Zoom-In 方案

2.1 时间维度 Zoom（Temporal Zoom）

方法	时间	会议	核心思路	Zoo
VideoTree	May 2024	CVPR 2025	查询自适应层次树	相关
FOCUS	Oct 2025	—	多臂赌博机关键帧选择	先定 帧，
VideoZoomer	Dec 2025	ICLR 2026投稿	RL学习的时间zoom	粗粒 →高
Zoom-Zero	Dec 2025	—	粗到精时间grounding	定位 帧， Cre
VideoExplorer	Jun 2025	—	"Think with Videos"迭代感知	子问 展感

2.2 空间+时间 Zoom（Spatial-Temporal Zoom）

方法	时间	会议	核心思路	Zo
LOVE-R1	Sep 2025	—	自适应空间-时间zoom+多步推理	低 zo
VideoMind	Mar 2025	ICLR 2026	Chain-of-LoRA四角色agent	Gr 辨 GP
Open-o3-Video	Oct 2025	—	显式时空证据推理	冷 间
VideoChat-R1.5	Sep 2025	NeurIPS 2025	视觉测试时缩放(VTTS)	迭 时