

优势坍塌问题

1、DPO 版多分类: {"label": "<ACT_SMOKE>"}

把动作拆成很多个 pair, (smoke>none),(smoke>eat),(smoke>phone)

比如正类头给每个动作一个分数 $s(x)$, 那么 DPO 风格的 pair loss 可以写成:

$$\log \pi_{\theta}(y^{+} | x) > \log \pi_{\theta}(y^{-} | x)$$

那么就可以分别算:

$$s_{\theta}(x, \text{smoke}) = \log \pi_{\theta}(y_{\text{smoke}} | x), \quad s_{\theta}(x, \text{eat}) = \log \pi_{\theta}(y_{\text{eat}} | x), \quad s_{\theta}(x, \text{none}) = \log \pi_{\theta}(y_{\text{none}} | x)$$

对一对 chosen / rejected:

$$L_{\text{DPO}}(x, a^{+}, a^{-}) = -\log \sigma(\beta [(\log \pi_{\theta}(a^{+} | x) - \log \pi_{\theta}(a^{-} | x)) - (\log \pi_{\text{ref}}(a^{+} | x) - \log \pi_{\text{ref}}(a^{-} | x))])$$

如果有多个错误类, 就把所有负类累加:

$$L_{\text{DPO-multi}}(x) = \sum_{a^{-} \neq a^{+}} w(x, a^{-}) [-\log \sigma(\beta [(\log \pi_{\theta}(a^{+} | x) - \log \pi_{\theta}(a^{-} | x)) - (\log \pi_{\text{ref}}(a^{+} | x) - \log \pi_{\text{ref}}(a^{-} | x))])]$$

2、带evidence: {"label": "<ACT_SMOKE>", "evidence":

["hand_to_mouth","cigarette","smoke"], "span":[1.2,2.0], "conf":"0.87"}]

把输出从“只给标签”改成“短证据 + 标签”, 让现有标签之外再多一层信号, 区分最主要混淆边界

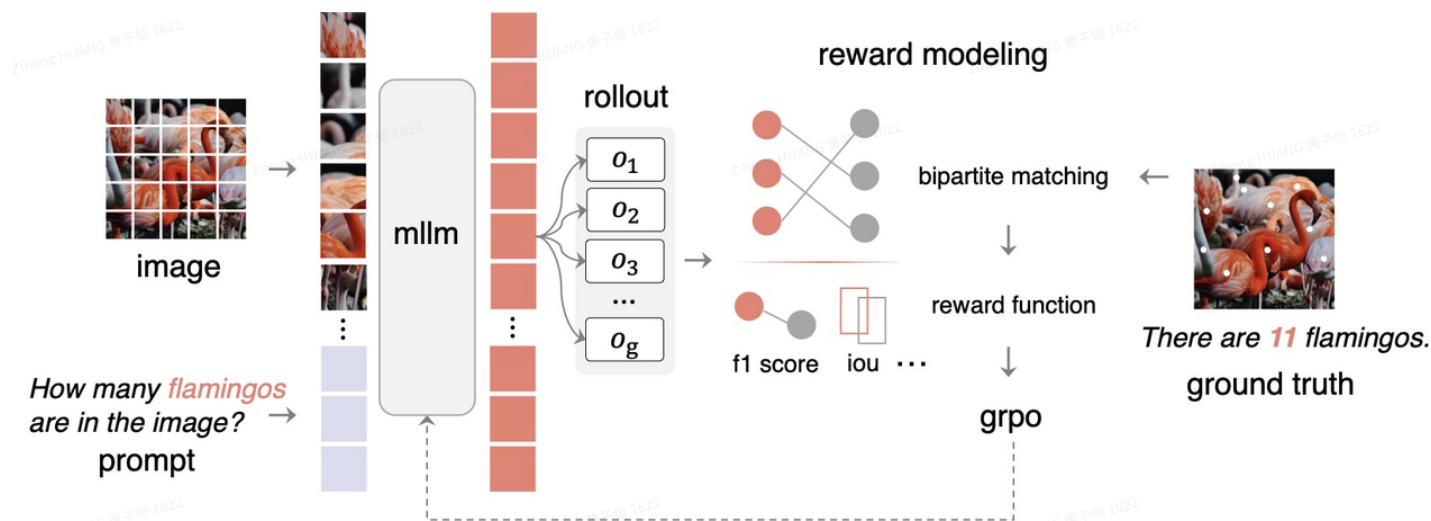
正确决策 > 错误决策

正确决策+正确evidence > 正确决策+错误evidence

正确决策+正确时间线索 > 正确决策+错误时间线索

1、Perception-R1: Pioneering Perception Policy with Reinforcement Learning (Nerulps2025)

仓库: <https://github.com/tongxiao2002/Perception-R1?tab=readme-ov-file>



核心思想：对当前很多视觉任务来说，显式思维链不是关键，真正关键的是**reward 设计和任务本身的感知复杂度**；RL 更适合那些感知空间更大、需要更多探索的任务，比如 counting 和 detection，而不一定适合已经很“单步化”的 grounding/OCR


Format reward：输出格式满足 `<answer>` 格式、坐标是 `[x1,y1,x2,y2]` 结构

Answer reward：答案本身和真值的匹配度，比如 IoU、F1、欧氏距离等： $ri = \Phi(o_i, z)$

- bounding box 用 IoU
- point 用欧氏距离
- OCR/counting/detection 用对应的精确匹配或统计指标




Multi-subject reward matching：当任务涉及多个对象时，模型输出的多个对象和 GT 的多个对象之间**谁对谁**并不天然对齐。不能顺序比，而是把这个问题定义成 **reward matching**，然后把它建模为一个二分图匹配问题，用匈牙利算法找最优分配

$$\hat{\sigma} = \arg \max_{\sigma \in \Omega_N} \sum_{i=1}^N \Phi(y_i, z_{\sigma(i)})$$



2、PAPO: Perception-Aware Policy Optimization for Multimodal Reasoning (ICLR 2026)

仓库：<https://mikewangwzhl.github.io/PAPO/>



核心思想：通过一个基于“原图 vs. 损坏图”的隐式感知损失，让模型在做 reasoning 的同时被迫真正依赖视觉输入，而不是只靠文本线索和语言先验；不需要额外标注、不需要更强 teacher、不需要额外神经 reward model，并且可以直接接在 GRPO 或 DAPO 上

Implicit Perception Loss：模型应该在“视觉输入更完整时”对当前回答更有信心；如果视觉输入被破坏后，它对同一回答的概率应该明显下降

- 同一条 rollout，在原始视觉输入 image 下的概率
- 同一条 rollout，在损坏视觉输入 image mask 下的概率

如果前者高于后者，说明这条回答更依赖真实视觉信息；如果比值接近 1，说明模型即使看不到关键图像内容也会给出差不多的回答，把它写成 KL 形式：

$$D_{KL}[\pi_\theta \| \pi_\theta^{\text{mask}}] = D_{KL}(\pi_\theta(o | q, I) \| \pi_\theta(o | q, I_{\text{mask}}))$$

Masking 策略：random masking、semantic-aware masking、Gaussian noise；论文默认 mask ratio 设为 0.6

Double Entropy Loss：因为理论上无上界的 KL，模型会有“作弊”空间：它不一定真的更看图，而可能通过把两个分布都推向异常高熵/不稳定状态来放大 KL

原始输入下策略的熵： $H[\pi_\theta] = \log \pi_\theta(o | q, I)$

masked 输入下策略的熵： $H[\pi_\theta^{\text{mask}}] = \log \pi_\theta(o | q, I_{\text{mask}})$

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{\{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(o|q, I)} \frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left\{ \min \left[r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1 - \epsilon_l, 1 + \epsilon_h) \hat{A}_{i,t} \right] - \beta \mathbb{D}_{KL}[\pi_\theta \| \pi_{\text{ref}}] \right\}$$


with $r_{i,t}(\theta) = \frac{\pi_\theta(o_{i,t}|q, I, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t}|q, I, o_{i,<t})}$

GRPO

$$\mathcal{J}_{\text{PAPO}_G}(\theta) = \mathbb{E}_{\{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(o|q, I)} \frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left\{ \min \left[r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1 - \epsilon_l, 1 + \epsilon_h) \hat{A}_{i,t} \right] - \beta \mathbb{D}_{KL}[\pi_\theta \| \pi_{\text{ref}}] + \gamma \mathbb{D}_{KL}[\pi_\theta \| \pi_\theta^{\text{mask}}] - \eta_1 \mathcal{H}[\pi_\theta] - \eta_2 \mathcal{H}[\pi_\theta^{\text{mask}}] \right\}$$


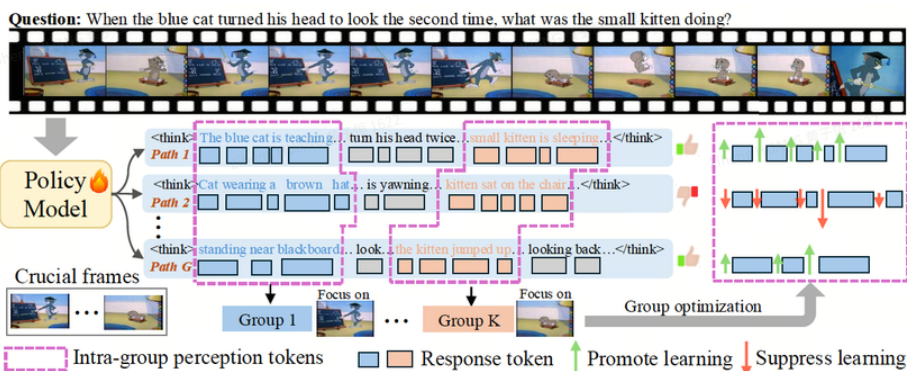
with $\mathbb{D}_{KL}[\pi_\theta \| \pi_\theta^{\text{mask}}] = \pi_\theta^{\text{prep}}(\theta) - \log \pi_\theta^{\text{prep}}(\theta) - 1$,
 $\mathcal{H}[\pi_\theta] = \log \pi_\theta(o|q, I)$, $\mathcal{H}[\pi_\theta^{\text{mask}}] = \log \pi_\theta(o|q, I_{\text{mask}})$

PAPO_G



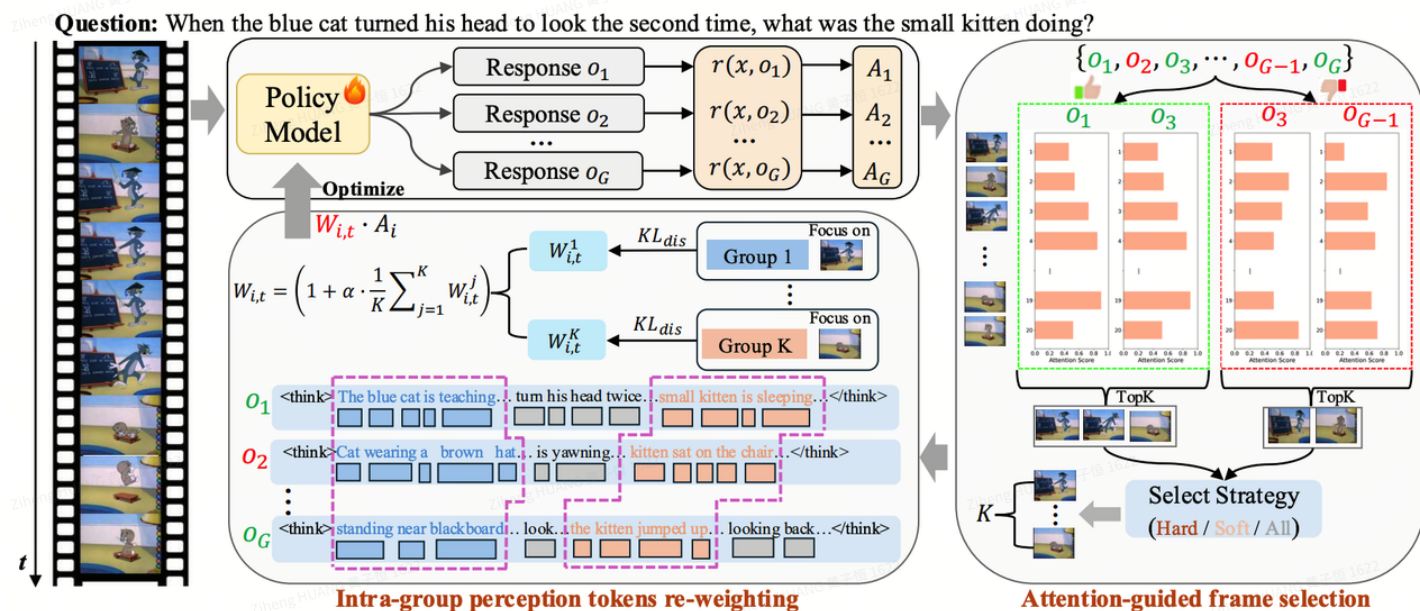
3、APPO: Attention-guided Perception Policy Optimization for Video Reasoning (CVPR2026)

仓库：<https://github.com/GeWu-Lab/APPO>



核心观点：在复杂视频推理里，提升 perception 比提升 reasoning 更重要。 通过交叉实验发现：在感知能力固定时，把 reasoning 从 Qwen3-8B 换到 OpenAI-o3，SEED-Bench-R1 上只提升约 **0.7%**；而在 reasoning 固定时，只把 perception 从 Qwen2.5-VL-7B 换到 Qwen2.5-VL-32B，就能带来 **1.4%** 提升

- 高 reward 的回答更可能关注到了真正关键的视频帧；低 reward 的回答则更可能漏看或看错这些帧。那么，组内高低 reward 回答之间的 attention 差异，本身就能提供一种“哪里是关键帧”的弱信号
- 如果不同回答里有一些 token 都主要关注同一关键帧，那么这些 token 就是所谓的 **intra-group perception tokens**，应该被赋予不同学习强度：高 reward 路径上的这类 token 要强化，低 reward 路径上的则要抑制



Attention-guided Frame Selection: 根据 reward 阈值 τ 把回答分成高 reward 集合 S1 和低 reward 集合 S2，实验里默认 $\tau=0.5$

token 到 frame 的 attention: $Attn(j, f_t) = \frac{1}{P_h \cdot |f_t|} \sum_h \sum_{v \in f_t} a_{jv}^{(h)}$ ，计算每一层的 token 和每一帧的 attention

response 到 frame 的 attention: 取该回答里最关注 frame f_t 的 top-K1 token:

$\phi(i) = \text{TopK } j(\text{Attn}(oi, j, f_t), K_1)$

每条回答最关注的若干帧：

对每条回答，再选出它最关注的 K2 帧： $\psi(i) = \text{TopK}_t \left(\text{Attn}(o_i, f_t), K_2 \right)$

分别在高 reward 组和低 reward 组里取并集： $\psi^{S_1} = \bigcup_{o_i \in S_1} \psi(i), \quad \psi^{S_2} = \bigcup_{o_i \in S_2} \psi(i)$

最后三种 frame selection 策略为：

$\psi' = \psi^{S_1} \setminus \psi^{S_2}$ (Hard) ; 高reward和低reward差集

$\psi' = \psi^{S_1}$ (Soft) ; 高reward集合

$\psi' = \psi^{S_1} \cup \psi^{S_2}$ (All) ; 高reward集合并低reward

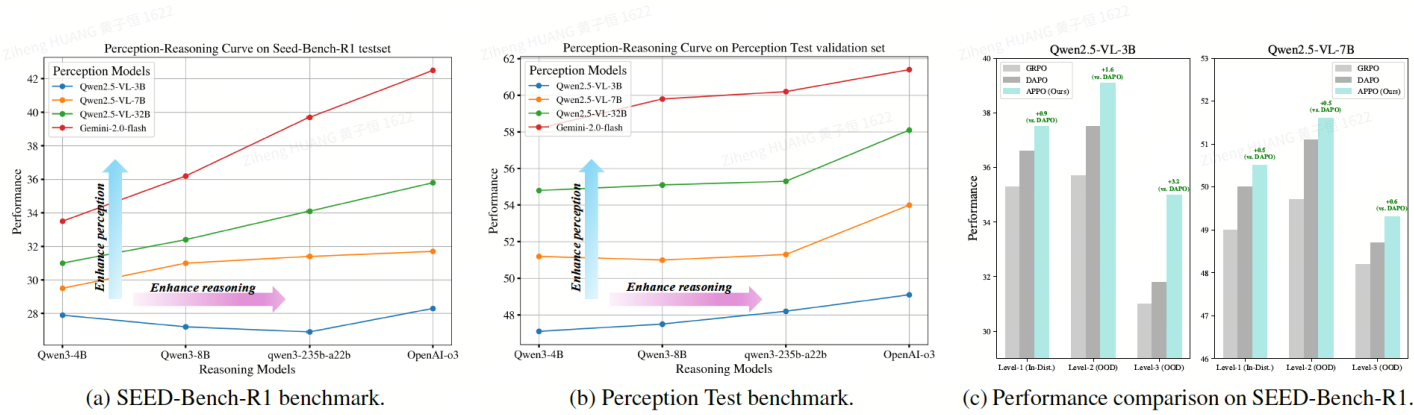
是把稀疏 outcome reward 变成 “哪些帧可能重要” 的 dense frame-level guidance

Intra-group perception tokens:


在选出的目标帧上，找出来自不同回答、但都主要关注同一帧的 token，把它们组成一个 token group，按信息差异赋予不同学习强度

KL divergence: 度量组内 token 分布和平均分布的差异

$$\sum_{i=1}^G D_{\text{KL}} \left(p(\Omega_{i,j}^{(k)}) ; E[\Omega_j^{(k)}] \right)$$



4、Seeing with You: Perception–Reasoning Coevolution for Multimodal Reasoning



PRCO 用同一个 MLLM policy，通过 role-specific prompting 让它轮流扮演两种角色。给定一个样本 (I,q,a)

Observer 在图像 I 和问题 q 条件下，生成一个与问题相关的证据 caption c；

Solver 在问题 q、caption c 以及可选图像输入 I 条件下，生成最终答案 o

Observer evidence captioning: caption 的“好坏”很难直接定义，因为不存在人工真值 caption，于是评价**这个 caption 对 Solver 最终答对有没有帮助**？

于是，Observer 的 reward 不是 caption 本身的匹配分，而是 **downstream utility**；如果某个 caption 能让 Solver 更容易答对，它就是好 caption；反之就是差 caption

$$R_{\text{obs}}(c) = (1 - m(c, q)) \cdot \mathbb{E}_{o \sim \pi_\theta(\cdot | q, c, I_s)} [\text{verifier}(o, a)]$$

leakage suppression: Observer 可能直接在 caption 里把答案泄漏出来，而不是提取视觉证据，加了一个 **LLM-based leakage checker**，输入是 caption 和问题，输出一个二值判断。如果被判定为泄漏，Observer 的 utility reward 会被压制

Solver reasoning:


- correctness reward: 最终答案是否和 GT 一致
- format reward: 输出是否符合要求格式

Caption-first warmup: 在训练最开始的 40 steps，作者把 Solver 的图像输入关掉，只让它根据 caption 作答；之后再恢复图像输入。原因是：如果一开始就同时给图像和 caption，Solver 很容易直接绕过 caption 看图答题，导致 Observer 的 caption utility 没有学习信号

5、AVATAR: Reinforcement Learning to See, Hear, and Reason Over Video (CVPR2026)

仓库: <https://github.com/yogkul2000/AVATAR>

开源内容: 代码、数据集

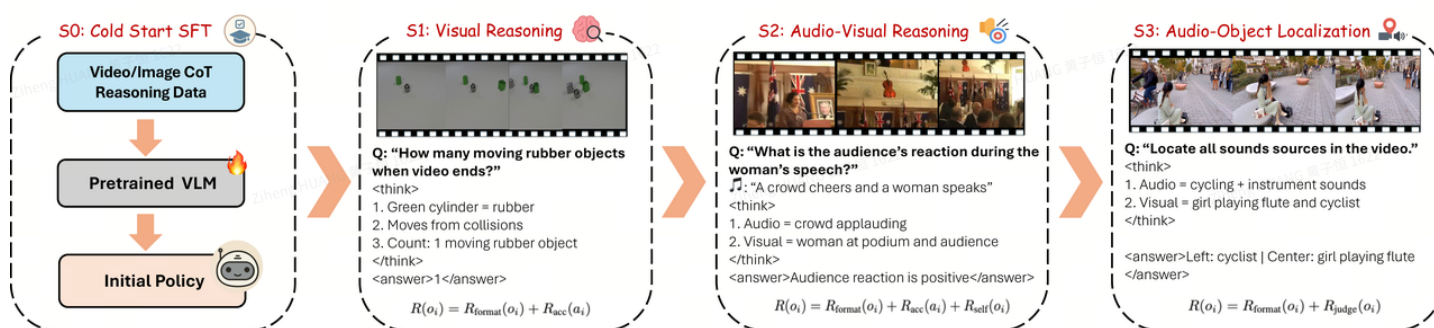


背景: 标准 GRPO 不仅样本效率低, 而且在长视频推理里会出现两种叠加失效: 一是组内 advantage 容易塌到 0, 二是整条 reasoning sequence 被统一分配同一个 credit, 导致模型不知道“前面哪段规划”“最后哪段综合”更关键

Hybrid Training with Selective Replay: 人为重建 reward variance,

$$J_{AVATAR}(\theta) = J_{on-policy}(\theta) + \alpha \cdot J_{off-policy}(\theta)$$


引入一个**分层 replay buffer**, 把历史轨迹按难度分层保存



6、DIVA-GRPO: ENHANCING MULTIMODAL REASONING THROUGH DIFFICULTY-ADAPTIVE VARIANT ADVANTAGE (ICLR2026)

仓库: <https://github.com/Siaaaaaa1/DIVA-GRPO>

开源内容: 代码、数据集 R1-ShareVL



核心思想：对每道题动态估计难度，再生成不同难度的语义一致变体，让同一原题对应的训练样本始终处在“可学”的难度带中

题目动态难度更新：

设一道原题当前有 m 个变体，每个变体 rollout k 次，则经验正确率：

$$\alpha = \frac{1}{mk} \sum_{i=1}^m \sum_{j=1}^k \mathbf{1}[y_{i,j} \text{ is correct}], \quad D_{\text{new}} = \text{clip}(D_{\text{old}} + \eta(0.5 - \alpha), D_{\min}, D_{\max})$$

$\alpha > 0.5$ ：这题对当前模型偏简单，难度下降。

$\alpha < 0.5$ ：这题偏难，难度上升

难度变体生成：

1. 简单题：文本侧包括改写、重组、轻微语言变化；图像侧包括旋转、高斯噪声、散斑噪声、模糊等
2. 中等题：生成语义等价的文本变体，提升泛化
3. 困难题：加入部分中间推理步骤，由gpto3生成并验证

Difficulty-Weighted Scaling: $\hat{A}(y_i | q^{(i)}) = \exp(k \cdot (D_q^{(i)} - \bar{D}_q) \cdot \text{sgn}(\tilde{A}(y_i))) \cdot \tilde{A}(y_i)$

难于平均的样本：正优势放大，负优势减弱

易于平均的样本：正优势压缩，负优势增强

RRB-Rescaling: $\hat{A}_{\text{range}}(y_i) = \Delta r_q \cdot \tilde{A}(y_i)$

如果一组样本的 reward range 本来就特别小，标准化也会把很小的差异夸大

组 A: $r = [0, 0, 0, 0.2]$, 均值 = 0.05, 标准差 ≈ 0.0866

z-score 后最后一个样本: $(0.2 - 0.05) / 0.0866 \approx 1.732$

组 B: $r = [0, 0, 0, 1]$, 均值 = 0.25, 标准差 ≈ 0.433

z-score 后最后一个样本同样是: $(1 - 0.25) / 0.433 \approx 1.732$

实验效果：

- 保持响应数一致时，步数加速 **1.90×**，计入变体生成时间后，总时间仍有 **1.76×** 加速。
- 保持数据量一致时，步数加速 **2.55×**，计入变体生成时间后，总时间仍有 **1.56×** 加速。

更少步数就达到最优点，优化了训练信号质量

=====

=====

APPO

Controllable Exploration in Hybrid-Policy RLVR for Multi-Modal Reasoning (ICLR2026)

仓库: <https://github.com/zhh6425/CalibRL>

开源内容: 代码

Quantile Advantage Estimation (QAE): A One-Line Baseline Swap for Entropy-Safe RL Reasoning (ICLR2026)

仓库: <https://github.com/junkangwu/QAE>

开源内容: 代码

GVPO: Group Variance Policy Optimization (NeurIPS 2025)

仓库: <https://github.com/jszkc/GVPO?tab=readme-ov-file>

开源内容: 代码

8、Prompt Augmentation Scales up GRPO Training on Mathematical Reasoning

仓库: <https://github.com/wenquanlu/prompt-augmentation-GRPO>

开源内容: 代码、模型

- **GVPO**
- **MAPO**
- **Prompt Augmentation**